

# **Relatório do Projeto de Processamento de Linguagem Natural para Detecção de Fake News**

## **Nome do Projeto:**

Detecção de Fake News usando Processamento de Linguagem Natural

## **Integrantes:**

José Jesus Andrade (Matrícula: 20190100030)

Matheus Victor Maciel (Matrícula: 20200025508)

Gabriel de Lucca Vieira (Matrícula: 20180042775)

## **1. Apresentação do Problema:**

Fake news representam uma ameaça significativa à disseminação de informações precisas. Neste projeto, abordamos o desafio de identificar notícias falsas por meio de técnicas avançadas de Processamento de Linguagem Natural (PLN). O objetivo é desenvolver modelos capazes de distinguir entre notícias verdadeiras e falsas com base em suas características linguísticas.

## **2. Objetivos:**

- Construir modelos de aprendizado de máquina para classificar notícias como verdadeiras ou falsas.
- Explorar técnicas de PLN, incluindo pré-processamento de texto, vetorização e modelagem.
- Avaliar o desempenho dos modelos em termos de precisão, recall e F1-score.

### **3. Dados Utilizados e Pré-processamento dos Dados:**

- Utilizamos dois conjuntos de dados: um contendo notícias falsas e outro contendo notícias verdadeiras.
- Os conjuntos foram combinados, e uma coluna “label” foi adicionada para indicar a classificação (1 para falsas, 0 para verdadeiras).
- Realizamos o pré-processamento, removendo símbolos, URLs, stopwords e aplicando a lematização.
- Realizamos análise exploratória, visualizando a distribuição de assuntos nas notícias e a ocorrência de n-gramas.

### **4. Modelagem (Detalhes sobre Arquitetura e Treinamento):**

- Random Forest Classifier:
  - Utilizamos a biblioteca Scikit-learn para implementar o classificador Random Forest.
  - Vetorizamos os textos usando TF-IDF.
  - Dividimos os dados em conjuntos de treino e teste.
  - Treinamos o modelo e avaliamos o desempenho usando matriz de confusão e relatório de classificação.
- Regressão Logística:
  - Utilizamos a Regressão Logística como outro classificador.
  - Aplicamos a técnica “One-vs-Rest” para lidar com problemas de classificação multiclasse.
  - Treinamos o modelo e avaliamos seu desempenho.
- Pipeline:
  - Criamos um pipeline que integra a vetorização TF-IDF e o classificador Random Forest.
  - Treinamos o modelo usando o pipeline e avaliamos seu desempenho.

### **5. Resultados:**

- Random Forest Classifier:
  - O modelo apresentou boa performance, conforme indicado pela matriz de confusão e relatório de classificação.
- Regressão Logística:
  - A Regressão Logística também demonstrou resultados satisfatórios, conforme observado na matriz de confusão e relatório de classificação.
- Pipeline (TF-IDF + Random Forest):
  - O pipeline mostrou-se eficaz na classificação de notícias falsas, apresentando resultados comparáveis aos outros modelos.

## **6. Considerações Finais:**

Este projeto oferece uma abordagem abrangente para a detecção de fake news, combinando técnicas de pré-processamento de texto, modelagem com diferentes algoritmos e avaliação de desempenho. Os resultados obtidos destacam a eficácia das abordagens de PLN na identificação de notícias falsas. Possíveis melhorias podem incluir ajustes nos parâmetros dos modelos e a exploração de outras técnicas de PLN.